เอกสารสเป็คระบบ

DPU Attendance / Face-in — ระบบลงเวลาด้วยใบหน้า

เวอร์ชันเอกสาร: 1.0 | วันที่: 18 กันยายน 2026
ผู้ใช้งาน: myHR (face-in.myhr.co.th)
โหมดที่ติดตั้งจริง: InsightFace ในเครื่อง (FACE_CORE_ENABLED=false) + GPU

> ตัวเลขความจุและ concurrent เป็นค่าประมาณจากสถาปัตยกรรมปัจจุบัน ยังไม่ได้ทำ load test เต็มระบบบนเซิร์ฟเวอร์นี้

1. ภาพรวม

ระบบลงเวลาเข้า–ออกงานด้วยใบหน้าสำหรับหลายบริษัท แอดมินจัดการพนักงานและลงทะเบียนใบหน้า พนักงานลงเวลาที่คีออสในเว็บแอดมิน ไม่มีแอปมือถือแยก

- จดจำใบหน้า: InsightFace รุ่น **buffalo_l** (embedding 512 มิติ)
- ค้นหา 1:N ภายในบริษัทเท่านั้น ไม่ค้นข้ามบริษัท
- เก็บ vector ใน PostgreSQL + ส่วนขยาย pgvector (ดัชนี HNSW, cosine)
- กันลงเวลาซ้ำด้วยช่วงเวลา (ค่าเริ่มต้น 5 นาที)
- ตรวจพิกัดสถานที่ (geofence) ตอนบันทึกลงเวลา

2. สถาปัตยกรรม (โหมดที่ใช้อยู่)

Docker Compose หลัง nginx — โค้ดถูก bake ใน image ต้อง rebuild หลังแก้ซอร์ส

บริการ	บทบาท
dpu-nginx	เกตเวย์พอร์ต HTTP อัปโหลดได้ถึง 500 MB, import timeout 1 ชั่วโมง, WebSocket คีออส
dpu-admin	Angular 17 หน้าแอดมิน + คีออส /company/timestamp-face
dpu-api	FastAPI + InsightFace + คิว GPU
dpu-db	PostgreSQL 16 + pgvector

เส้นทางข้อมูล: เบราว์เซอร์ → nginx → admin (หน้าเว็บ) หรือ api (ใบหน้า / HR) → Postgres

> **FACE_CORE_ENABLED** เป็นสวิตช์ส่งงานวิชันไปบริการ face-core แยก
> เซิร์ฟเวอร์นี้ตั้ง **false** ไม่จำเป็นต้องมี face-core

3. สแต็กซอฟต์แวร์

ชั้น	เทคโนโลยี
UI	Angular 17 (Web-Manage)
API	FastAPI + Uvicorn (Python 3.12)

ใบหน้า	InsightFace 0.7.3 buffalo_l, ONNX Runtime GPU 1.21.0
ฐานข้อมูล	pgvector/pgvector:pg16, embedding vector(512)
เกตเวย์	nginx 1.27, client_max_body_size 500m
รันไทม์	Docker Compose, image API จาก nvidia/cuda:12.8.1-cudnn

4. สเป็คฮาร์ดแวร์ที่ตรวจบนเซิร์ฟเวอร์

รายการ	ที่พบบนเครื่อง myhr
GPU	NVIDIA Quadro RTX 5000 จำนวน 2 ใบ (VRAM 16 GB/ใบ)
ไดรเวอร์ที่ต้องตรงกัน	เคอร์เนลโมดูลกับ NVML ต้องเป็นรุ่นเดียวกัน (เช่น 580.178)
GPU ที่ระบบใช้ตอนนี้	cuda:0 ใบเดียว (ใบที่สองยังไม่ถูกใช้)
NVIDIA persistenced	ต้องมี /run/nvidia-persistenced/socket เพื่อให้คอนเทนเนอร์ GPU ขึ้น

> บน nvidia-smi พบคำเตือน infoROM corrupted ทั้งสองใบ ไม่ได้บล็อกการรัน แต่ควรสำรองและติดตามสุขภาพ GPU

5. ความจุจำนวนคน (gallery)

ค้นหาใบหน้าจำกัดต่อบริษัท + ดัชนี HNSW — embedding ในเบสเล็กมาก (~2 KB/คน) จุดที่โตคือไฟล์ JPEG

ระดับ	จำนวนโดยประมาณ	หมายเหตุ
ใช้งานสบาย	2,500 – 10,000 คน / บริษัท	ตรงกับชุด import หลักพัน–หมื่น
ยังรองรับ	~20,000 – 50,000 คน	ค้นหายังเร็ว ดิสก์รูปจะโตก่อน CPU
ต้องออกแบบใหม่	แสนคนขึ้นไป หรือค้นข้ามทุกบริษัท	ไม่ใช่โหมดปัจจุบันของระบบ

ประมาณการดิสก์รูป: หลักสิบ–ร้อย KB ต่อไฟล์ × 2 ชุด (โปรไฟล์ + ใบหน้าที่ลงทะเบียน)

6. Concurrent (ใช้งานพร้อมกัน)

คอขวดคือคิว GPU ไม่ใช่หน้าเว็บแอดมิน

พารามิเตอร์	ค่าเริ่มต้น
FACE_GPU_WORKERS	1 (ประมวลผลใบหน้าทีละงาน)
FACE_GPU_QUEUE_SIZE	64 (คิวรอสูงสุด)
Throughput โดยประมาณบน RTX 5000	ประมาณ 5–10 งานใบหน้า / วินาที

สถานการณ์	ความเหมาะสม
คีออส 1 จอ คนเดินผ่านเป็นกลุ่ม	รองรับดี

คีออส 2–4 จอ พร้อมกัน	ยังไหว เริ่มมีงานรอในคิว
คีออส 10+ จอ หรือคนอัดหน้ากล้องพร้อมกันมาก	หน่วง งานรอเต็มคิว 64
แอดมินเปิดเว็บพร้อมกันหลายสิบคน	ไม่ใช่คอขวด
Import Excel+ZIP หลักพันรูป	รันทีละรูปบน GPU ใช้เวลาหลายนาที

ตรวจคิวจริง: `GET /face/queue-stats` ดู pending / active / workers

7. คีออสลงเวลา

- เส้นทาง: /company/timestamp-face (เต็มจอ ไม่มีแอปมือถือแยก)
- โหมดหลัก: WebSocket /face/ws/kiosk (identify + walk-by check-in)
- สำรอง: HTTP walk-by หาก WS ใช้ไม่ได้
- หลายคนในเฟรม: ติดตามด้วย IoU ส่งครอปใบหน้า ไม่ล็อกกล้องทั้งจอให้คนเดียว
- ค้นหาและลงเวลาต้องส่ง companyId — ไม่จับคู่ข้ามบริษัท
- กันลงเวลาซ้ำ: CHECK_IN_DEDUPE_SECONDS (ค่าเริ่มต้น 300 วินาที)

8. นำเข้าพนักงาน (Excel + รูป)

รายการ	สเป็ค
API	GET .../import-template และ POST .../import (file=xlsx, photos=zip)
ขนาดอัปโหลด	nginx 500 MB (HTTPS ด้านนอกต้องตั้ง client_max_body_size ด้วย มิฉะนั้นได้ 413)
เกณฑ์เบลอตอน import	IMAGE_BLUR_THRESHOLD_IMPORT=0 ไม่ตัดรูปเบลอจากระบบอื่น (ยังต้องเจอใบหน้า)
เกณฑ์เบลอตอนคีออส / เพิ่มใบหน้า	IMAGE_BLUR_THRESHOLD=20.0
Import ซ้ำ	อีเมลที่มีในบริษัทแล้ว = error ไม่แก้ข้อมูลเดิม ไม่ลงใบหน้าซ้ำ แถวอื่นทำต่อได้

9. พื้นที่จัดเก็บ

ที่เก็บ	เนื้อหา	ลบหลังเทรน/import เสร็จ
ตาราง face_encoding	vector 512-d สำหรับจับคู่	ห้ามลบ ถ้าลบจะลงเวลาด้วยใบหน้าไม่ได้
enrolled_images	รูปใบหน้าที่ลงทะเบียน	ลบได้ถ้าไม่ต้องดูแกลเลอรี — ลงเวลายังใช้ vector ในเบส
uploaded_images	รูปโปรไฟล์ + รูปตอนลงเวลา	อย่าลบทั้งโฟลเดอร์ UI และหลักฐานลงเวลาจะหาย
temp_images	ไฟล์ชั่วคราว	ลบของค้างได้

เช็กขนาดเบส: `SELECT pg_size_pretty(pg_database_size('dpu'));`
เช็กขนาดรูป: `du -sh /app/enrolled_images /app/uploaded_images` ในคอนเทนเนอร์ dpu-api

10. URL สำคัญ

เส้นทาง	หน้าที่
/	เว็บแอดมิน
/company/timestamp-face	คีออสลงเวลา
/docs	OpenAPI
/face/queue-stats	สุขภาพคิว GPU

11. ข้อแนะนำเมื่อจะขยาย

- เพิ่มคีออสพร้อมกันหลายจุด: ตั้ง FACE_GPU_WORKERS และใช้ GPU ใบที่สอง หรือแยกวิชันไป Face Core
- ไดรเวอร์ NVIDIA หลังอัปเดตต้องรีบูต ให้เคอร์เนลโมดูลตรงกับ NVML
- อัปโหลดผ่าน HTTPS ต้องตั้งขนาดบอดี้ที่ nginx ฝั่ง TLS ไม่ใช่แค่ใน Docker
- หลังแก้โค้ด API/UI/nginx ต้อง rebuild image ที่เกี่ยวข้อง

เอกสารนี้อ้างอิงโค้ดใน repo facescan-timeattendance (DPU Attendance) และการตรวจบนเซิร์ฟเวอร์ production ณ วันที่ระบุ