สรุปสำหรับผู้บริหาร — ความจุระบบลงเวลาด้วยใบหน้า (Face Kiosk)

วันที่วัดล่าสุด: 23 กันยายน 2026 (รอบ saturation / dual-API)

ระบบ: Face Scan Time Attendance (DPU) · เซิร์ฟเวอร์ `face-in` (`10.50.0.117`)

เอกสารเทคนิค: KIOSK-LOADTEST-SATURATION.md · ตารางรอบ 3 · ตารางรอบ 2 · ตารางรอบ dual-API

รายงานรอบก่อน (conservative): KIOSK-LOADTEST-WORKERS2-CAPACITY.md

ไฟล์ PDF: EXEC-SUMMARY-KIOSK-CAPACITY.pdf *(อาจยังเป็นตัวเลขรอบก่อน — ดูตารางด้านล่างเป็นปัจจุบัน)*

---

1. โปรดักต์นี้ทำอะไร

ระบบลงเวลาทำงานด้วยการจดจำใบหน้า:

1. พนักงานยืนหน้ากล้องที่ **จอคีออส** (ไม่ต้องแตะเครื่อง)
2. ระบบตรวจจับใบหน้า → จับคู่กับข้อมูลที่ลงทะเบียนไว้ → บันทึกเวลาเข้า/ออก
3. แอดมินจัดการบริษัท พนักงาน สถานที่ และนำเข้าข้อมูลผ่านเว็บ

คอขวดหลักของความเร็วอยู่ที่ **การประมวลผลใบหน้าบนการ์ดจอ (GPU)** ของเซิร์ฟเวอร์

---

2. สเป็คที่ทดสอบ (รอบล่าสุด)

รายการ	ค่าที่ใช้ทดสอบ
เซิร์ฟเวอร์	production (`10.50.0.117`)
การ์ดจอ (GPU)	**2 ใบ** · Quadro RTX 5000 · 16 GB/ใบ
สถาปัตยกรรม	**API 2 process** แยกตาม GPU (nginx กระจายโหลด) · คนละ 2 workers
วิธีวัด	จำลองจอคีออสหลายจอ · เฟรมขนาดใกล้ของจริง (~1280 px, JPEG q70)
เกณฑ์คุณภาพ (UX)	กรอบใบหน้า ≤ ~0.55 วินาที · ทิ้งเฟรม ≤ 5%

> รอบก่อนใช้ process เดียว + เฟรมทดสอบใหญ่เกินจริง ทำให้ตัวเลข **conservative** (ต่ำกว่าความจุจริง)

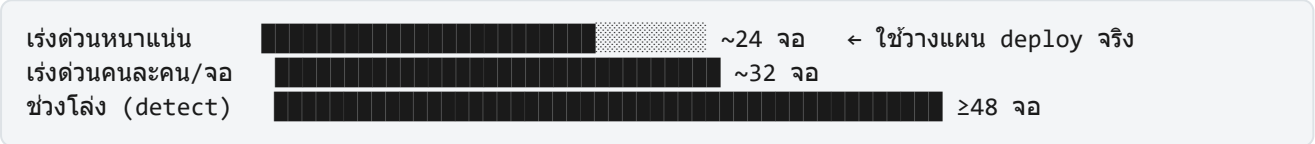
---

3. สรุปผลในหนึ่งหน้า

คำตอบสั้น ๆ สำหรับวางแผนติดตั้ง

สถานการณ์หน้างาน	รอบ 3 (ล่าสุด, 4 process)	รอบ 2 (2 process)	รอบ dual-API	รอบก่อน
เร่งด่วนหนาแน่น (~หลายคนในกล้อง)	**ไม่เกิน 24 จอ**	16 จอ	6 จอ	4–5 จอ
เร่งด่วนคนละคนต่อจอ	**ไม่เกิน 32 จอ**	24 จอ	12 จอ	8 จอ
ช่วงโล่ง / กล้องรอคน	**≥ 48 จอ** (ยังไม่ชนเพดาน)	≥ 32 จอ	24 จอ	12 จอ

ภาพรวมความจุ (หลังปรับรอบ 3)



สิ่งที่พิสูจน์แล้วจากการวัดรอบนี้

- การ์ดจอ **ทั้ง 2 ใบมี process ของระบบจริง** (~2 GB/ใบ)
- แยก API ตาม GPU + แก้การ pin อุปกรณ์ แล้ว GPU1 ไม่ถูกทิ้งว่างเหมือนรอบก่อน
- รอบ 2 (ลดงานต่อคำขอ: ตรวจจับที่ 320 px แล้วจดจำทันที, ไม่เขียนไฟล์ชั่วคราว, worker 3 ต่อ process) ทำให้เพดานชั่วโมงเร่งด่วน **เพิ่มจาก 6 → 16 จอ** โดยไม่แตะฮาร์ดแวร์
- รอบ 3 (API 2 process ต่อการ์ด = 4 process ใช้ CPU 32 core ที่ว่างอยู่ + ย้ายบริการถอดเสียง whisper ออกจาก GPU0) เพดานเร่งด่วน **16 → 24 จอ**, คนละคนต่อจอ **24 → 32 จอ**
- ตัวเลขนี้วัดด้วยโหลดที่หนักกว่าจริง (จอส่งภาพ 11 เฟรม/วินาทีตลอด) — หน้าบ้านรอบ 2 ส่งน้อยลงเมื่อคนยืนนิ่ง จอจริงจึงรับได้มากกว่านี้
- ยังไม่จำเป็นต้องแยก Face Core แค่เพื่อ "ใช้ GPU ให้เต็ม" บนเครื่องนี้ (GPU ยังใช้เฉลี่ย ~11%)

---

4. แปลผลเป็นภาษาธุรกิจ

คำถามของผู้บริหาร	คำตอบจากผลการทดสอบล่าสุด
ติดตั้งกี่จอต่อเซิร์ฟเวอร์นี้ได้โดยยังลื่น?	**24 จอ** สำหรับชั่วโมงเร่งด่วนที่มีคนหนาแน่น
ถ้าส่วนใหญ่คนละคนต่อจอ?	ได้ถึงประมาณ **32 จอ**
เกินแล้วเกิดอะไรขึ้น?	ภาพช้า กรอบกระพริบ ทิ้งเฟรมสูง — ระบบยังลงเวลาได้แต่ UX แย่
ถ้าต้องการมากกว่า 32–48 จอ?	GPU ยังใช้แค่ ~16% — เพิ่ม process ต่อการ์ดได้อีก แต่ผลตอบแทนเริ่มลด; ถัดจากนั้นคือสเกลข้ามเครื่อง (Face Core) หรือแยก DB

---

5. ข้อเสนอแนะเชิงปฏิบัติ

1. **เพดานติดตั้งแนะนำ = 24 จอ** สำหรับการใช้งานจริงแบบหนาแน่นบนเซิร์ฟเวอร์นี้ (เผื่อ margin ใช้ 16–20)

2. โซนที่คนส่วนใหญ่ยืนคนละจอ: วางแผนได้ถึง **32 จอ**
3. **ยังไม่ต้องลงทุนแยก Face Core** เพื่อเพิ่มความจุบนเครื่องใบนี้ — งานนั้นเหมาะตอนสเกลหลายเครื่อง
4. เก็บเกณฑ์ UX: ตอบสนองกรอบ ≤ ~0.55 วินาที · ทิ้งเฟรม ≤ 5% ในชั่วโมงเร่งด่วน

---

6. สรุปหนึ่งประโยค

หลังปรับรอบ 3 (ใช้ GPU สองใบจริง + ลดงานต่อคำขอ + API 4 process) เซิร์ฟเวอร์ Quadro RTX 5000 สองใบนี้รองรับจอคีออสได้อย่างลื่นประมาณ 24 จอในช่วงเร่งด่วนหนาแน่น และราว 32 จอถ้าโดยทั่วไปมีคนละคนต่อจอ — เพิ่มจากจุดเริ่มต้น ~4 เท่าโดยไม่ซื้อฮาร์ดแวร์เพิ่ม

จัดทำจากผลการโหลดเทส saturation วันที่ 23 ก.ย. 2026